

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN MÔN HỌC

Chủ đề: Vehicle Detection and Counting in Traffic Surveillance

Môn học: Thị giác máy tính

GV lý thuyết: TS. Trần Thái Sơn

ThS. Phạm Minh Hoàng

Lớp: 23TN

SV thực hiện: Hoàng Ngọc Phú – 23120010

Hoàng Ngọc Quý – 23120077

Nguyễn Duy Bảo – 23120113

TP. Hồ Chí Minh, tháng 6 năm 2026

Mục lục

Mục lục	1
Danh sách hình vẽ	2
Danh sách bảng	3
1 Tổng quan	4
1.1 Động lực nghiên cứu	4
1.2 Phát biểu bài toán	4
1.3 Ý nghĩa khoa học và thực tiễn	5
1.3.1 Ý nghĩa khoa học	5
1.3.2 Ý nghĩa thực tiễn	5
1.4 Thách thức của bài toán	5
1.5 Phạm vi nghiên cứu	5
2 Các nghiên cứu liên quan	5
2.1 Phát hiện phương tiện	6
2.2 Theo dõi phương tiện	6
2.3 Đếm phương tiện	6
3 Hướng tiếp cận dự kiến	7
3.1 Các vấn đề của bài toán sau khi khảo sát các công trình liên quan	7
3.2 Hướng tiếp cận của đề tài	7
3.3 Mô hình YOLOv8	7
3.3.1 Biến thể YOLOv8n	8
3.4 Thuật toán BYTE	8
4 Thí nghiệm	9
4.1 Thiết lập thực nghiệm	9
4.1.1 Tập dữ liệu	9
4.1.2 Các độ đo đánh giá	9
4.1.3 Fine-tuning mô hình YOLOv8n	12
4.1.4 Tham số cho bộ theo dõi	12
4.2 Kết quả thực nghiệm	13
4.2.1 Kết quả quá trình huấn luyện YOLOv8n	13
4.2.2 Kết quả trên tập kiểm tra của mô hình YOLOv8n	19
4.2.3 Kết quả chọn bộ theo dõi	20
4.2.4 Kết quả theo dõi trên tập kiểm tra	21
5 Kết luận	22
A Thông tin nhóm	24
A.1 Thông tin thành viên	24
B Mã nguồn bài làm đồ án	24
Tài liệu tham khảo	25

Danh sách hình vẽ

1	Phân bố nhãn, vị trí tâm và kích thước hộp bao của các đối tượng trong tập dữ liệu.	14
2	Kết quả huấn luyện và xác thực của mô hình YOLOv8n trong quá trình fine-tuning	15
3	Đường cong Precision theo ngưỡng confidence	16
4	Đường cong Recall theo ngưỡng confidence	17
5	Đường cong Precision–Recall của mô hình	18
6	Đường cong F1-score theo ngưỡng confidence	19
7	Ma trận nhầm lẫn chuẩn hóa của mô hình	20
8	Kết quả đánh giá theo dõi bằng độ đo HOTA	22

Danh sách bảng

1	Các siêu tham số cho thuật toán SORT và BYTE	13
2	So sánh kết quả trên tập kiểm tra giữa YOLOv8n và YOLOv5nu	20
3	So sánh kết quả theo dõi của SORT và BYTE trên tập xác thực	21
4	Kết quả đánh giá quá trình theo dõi trên tập kiểm tra	21
5	Thông tin thành viên nhóm	24

1 Tổng quan

1.1 Động lực nghiên cứu

Sự phát triển nhanh chóng của quá trình đô thị hóa cùng với sự gia tăng liên tục của số lượng phương tiện giao thông đã tạo ra nhiều thách thức đối với công tác quản lý và điều hành giao thông tại các đô thị hiện đại. Các vấn đề như ùn tắc giao thông, tai nạn đường bộ và ô nhiễm môi trường ngày càng trở nên phổ biến, đòi hỏi các cơ quan quản lý phải có khả năng giám sát và phân tích tình hình giao thông một cách hiệu quả. Trong bối cảnh đó, Hệ thống Giao thông Thông minh (Intelligent Transportation Systems – ITS) đã trở thành một hướng nghiên cứu quan trọng nhằm nâng cao mức độ an toàn, hiệu quả và tính bền vững của hệ thống giao thông (Yang & Pun-Cheng, 2018).

Trong Hệ thống Giao thông Thông minh (ITS), phát hiện và đếm phương tiện là một trong những nhiệm vụ quan trọng, cung cấp dữ liệu phục vụ nhiều ứng dụng như giám sát lưu lượng giao thông, điều khiển tín hiệu giao thông, phát hiện ùn tắc, dự báo lưu lượng phương tiện và hỗ trợ quy hoạch hạ tầng giao thông (Yang & Pun-Cheng, 2018). Trước đây, việc thu thập thông tin giao thông chủ yếu dựa trên các cảm biến chuyên dụng như vòng từ cảm ứng, radar hoặc cảm biến laser. Mặc dù các thiết bị này có khả năng cung cấp dữ liệu tương đối chính xác, chúng thường đòi hỏi chi phí lắp đặt và bảo trì cao, đồng thời dễ bị ảnh hưởng bởi các điều kiện môi trường (Yang & Pun-Cheng, 2018).

Sự phát triển và phổ biến của các hệ thống camera giám sát giao thông đã tạo ra nguồn dữ liệu hình ảnh và video phong phú, mở ra hướng tiếp cận mới cho việc thu thập và phân tích thông tin giao thông trên quy mô lớn. So với các loại cảm biến truyền thống, camera có ưu thế về chi phí, tính linh hoạt và khả năng cung cấp thông tin trực quan phục vụ nhiều nhiệm vụ phân tích khác nhau (Yang & Pun-Cheng, 2018).

Nhờ sự phát triển của học sâu, các hệ thống phát hiện và đếm phương tiện dựa trên dữ liệu video đã đạt được độ chính xác cao và có khả năng hoạt động hiệu quả trong các bối cảnh giao thông thực tế, đặc biệt trên các tuyến đường cao tốc và đô thị (Song, Liang, Li, Dai, & Yun, 2019).

Vì vậy, nghiên cứu các phương pháp phát hiện và đếm phương tiện từ video giám sát giao thông không chỉ mang ý nghĩa khoa học trong lĩnh vực thị giác máy tính mà còn có giá trị thực tiễn đối với việc xây dựng và phát triển các hệ thống giao thông thông minh.

1.2 Phát biểu bài toán

Bài toán phát hiện và đếm phương tiện trong giám sát giao thông sử dụng dữ liệu đầu vào là video hoặc chuỗi ảnh được thu nhận từ các camera giám sát lắp đặt tại các tuyến đường, nút giao thông hoặc đường cao tốc. Mục tiêu của hệ thống là xác định vị trí của các phương tiện xuất hiện trong từng khung hình, theo dõi sự di chuyển của chúng giữa các khung hình liên tiếp và thực hiện đếm số lượng phương tiện đi qua một vùng quan sát xác định trước. Thông tin thu được từ quá trình phát hiện và đếm phương tiện là cơ sở cho nhiều ứng dụng trong hệ thống giao thông thông minh như giám sát lưu lượng giao thông, phát hiện ùn tắc và hỗ trợ quản lý giao thông (Yang & Pun-Cheng, 2018).

Kết quả đầu ra của hệ thống bao gồm vị trí phương tiện dưới dạng hộp giới hạn, thông tin theo dõi đối tượng và số lượng phương tiện được ghi nhận trong khoảng thời gian quan sát. Hệ thống cần đảm bảo độ chính xác cao trong điều kiện giao thông thực tế, đồng thời đáp ứng yêu cầu xử lý gần thời gian thực nhằm phục vụ hiệu quả cho các

ứng dụng giám sát và điều hành giao thông.

1.3 Ý nghĩa khoa học và thực tiễn

1.3.1 Ý nghĩa khoa học

Đề tài góp phần nghiên cứu khả năng ứng dụng các mô hình học sâu trong bài toán phát hiện đối tượng và phân tích dữ liệu giao thông từ video. Việc đánh giá hiệu quả của các mô hình phát hiện phương tiện trong những điều kiện giao thông khác nhau giúp bổ sung cơ sở thực nghiệm cho lĩnh vực thị giác máy tính và giao thông thông minh. Ngoài ra, đề tài cũng tạo tiền đề cho các nghiên cứu liên quan đến theo dõi đối tượng, phân tích hành vi giao thông và dự báo lưu lượng phương tiện trong tương lai.

1.3.2 Ý nghĩa thực tiễn

Hệ thống phát hiện và đếm phương tiện có thể được ứng dụng trong công tác giám sát giao thông tự động, hỗ trợ điều khiển tín hiệu giao thông thích ứng, đánh giá mật độ phương tiện, phát hiện ùn tắc và thu thập dữ liệu phục vụ quy hoạch hạ tầng giao thông. Việc tự động hóa quá trình thu thập dữ liệu giao thông giúp giảm chi phí vận hành, nâng cao độ chính xác và cung cấp thông tin theo thời gian thực cho các cơ quan quản lý giao thông.

1.4 Thách thức của bài toán

Mặc dù các phương pháp học sâu đã đạt được nhiều tiến bộ trong những năm gần đây, bài toán phát hiện và đếm phương tiện trong môi trường thực tế vẫn còn nhiều thách thức. Điều kiện ánh sáng thay đổi giữa ban ngày và ban đêm, các hiện tượng thời tiết bất lợi như mưa hoặc sương mù, hiện tượng che khuất giữa các phương tiện và sự khác biệt về góc quan sát của camera đều có thể ảnh hưởng đến độ chính xác của hệ thống. Bên cạnh đó, sự đa dạng về kích thước và chủng loại phương tiện cũng làm tăng độ phức tạp của quá trình phát hiện và theo dõi đối tượng (Yang & Pun-Cheng, 2018).

1.5 Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu bài toán phát hiện, theo dõi và đếm phương tiện giao thông đường bộ dựa trên dữ liệu video từ các camera giám sát cố định. Các thí nghiệm được thực hiện trên bộ dữ liệu UA-DETRAC, bao gồm các phương tiện như ô tô, xe buýt, xe tải nhẹ và các loại phương tiện khác được ghi nhận trong tập dữ liệu.

Về phương pháp, đề tài sử dụng mô hình phát hiện đối tượng dựa trên học sâu để xác định vị trí phương tiện trong từng khung hình, kết hợp với thuật toán theo dõi đối tượng nhằm duy trì định danh của phương tiện và thực hiện đếm phương tiện khi chúng đi qua vùng quan sát xác định trước.

2 Các nghiên cứu liên quan

Phần này trình bày các nghiên cứu liên quan cho các bài toán phát hiện, theo dõi và đếm phương tiện.

2.1 Phát hiện phương tiện

Phát hiện phương tiện là một trong bước đầu tiên để nhận được các thông tin trong luồng giao thông. Phát hiện nhằm xác định vị trí và phân loại phương tiện.

Các phương pháp thị giác máy tính cổ điển có thể chia thành ba hướng: chênh lệch khung hình (frame difference) có ưu điểm về sự tối giản trong thuật toán và tốc độ tính toán nhanh, nhưng thường chỉ nhận diện được một phần đối tượng chuyển động do hạn chế của việc đối chiếu sự khác biệt giữa các khung hình liên tiếp (Song et al., 2019). Phương pháp luồng quang học (optical flow) khắc phục được việc thiếu hụt thông tin bằng cách cung cấp trường chuyển động toàn diện trên toàn bức ảnh, song khối lượng tính toán khổng lồ lại làm suy giảm đáng kể tốc độ xử lý thời gian thực (Dai et al., 2019). Đối với kỹ thuật trừ nền (background subtraction), đối tượng được trích xuất dựa trên độ lệch giữa ảnh đầu vào và mô hình bối cảnh; tuy nhiên, thách thức lớn nhất của kỹ thuật này là sự khó khăn trong việc duy trì một mô hình nền chuẩn xác trước các biến động môi trường như thay đổi ánh sáng hay bóng đổ (Dai et al., 2019).

Trong quá khứ, các phương pháp chủ yếu dựa vào các đặc trưng được thiết kế thủ công như SIFT, HOG và Haar-like, sau đó đưa các đặc trưng này vào bộ phân loại để huấn luyện, ví dụ SVM và Adaboost, v.v. (Dai et al., 2019). Tuy nhiên, phương pháp này có độ ổn định kém và tốc độ tính toán chậm.

Hiện nay, hướng học sâu dùng mạng nơ-ron tích chập (CNN) khắc phục được nhiều hạn chế đó. Trong số các mô hình học sâu, nhóm hai giai đoạn (R-CNN, SPPNet, Fast R-CNN, Faster R-CNN) đạt độ chính xác cao nhờ sinh vùng đề xuất và sử dụng CNN để chiết xuất đặc trưng, nhưng tốc độ xử lý chậm, khó đáp ứng thời gian thực. Nhóm một giai đoạn (YOLO, SSD) đạt sự cân bằng tốt hơn giữa độ chính xác và tốc độ, phù hợp với các hệ thống giám sát giao thông. Các phiên bản YOLO mới hơn (YOLOv8, YOLOv9, YOLOv10, YOLOv11, YOLOv12, YOLOv26) liên tục cải tiến kiến trúc, tăng cường cơ chế chú ý và tối ưu hóa hậu xử lý, giúp nâng cao khả năng phát hiện vật thể và giảm độ trễ.

2.2 Theo dõi phương tiện

Mục tiêu của quá trình theo dõi phương tiện là xây dựng quỹ đạo chuyển động của đối tượng xuyên suốt các khung hình. Đối với bài toán theo dõi đa đối tượng (MOT), chiến lược chủ đạo là theo dõi dựa trên phát hiện (Detection-Based Tracking, DBT), trong đó quá trình ghép nối hoàn toàn phụ thuộc vào các hộp bao do mô hình nhận diện cung cấp. Các thuật toán nền tảng như SORT và DeepSORT đã định hình chiến lược này bằng cách kết hợp dự đoán động học và đối sánh đặc trưng ngoại hình. Dựa trên nền tảng đó, các phương pháp hiện đại như BYTE hay OC-SORT tiếp tục tối ưu hóa quá trình liên kết bằng cách tận dụng cả những hộp bao có độ tin cậy thấp và xử lý tốt hơn các tình huống vật thể bị che khuất, qua đó giảm thiểu đáng kể hiện tượng nhảy ID (ID switch) và duy trì quỹ đạo ổn định.

2.3 Đếm phương tiện

Đếm phương tiện sử dụng quỹ đạo đã theo dõi để thống kê số lượng, hướng và loại phương tiện. Các nghiên cứu hiện tại chủ yếu được phân loại thành ba hướng tiếp cận: phương pháp dựa trên hồi quy (regression-based), phân cụm (cluster-based) và phát hiện (detection-based) (Dai et al., 2019). Phương pháp hồi quy tập trung mô hình hóa các hàm dự đoán thông qua việc khai thác đặc trưng không gian từ các vùng ảnh. Mặc dù

đạt hiệu quả cao trong các bối cảnh đông đúc (nơi ranh giới giữa các đối tượng không rõ ràng), phương pháp này lại gặp khó khăn trước hiện tượng biến dạng phối cảnh và các đối tượng có kích thước lớn, do chỉ có thể cung cấp vị trí bao quát của đối tượng (Shokri, Larouche, & Homayouni, 2025). Phương pháp phân cụm tiến hành theo dõi các đặc trưng ngoại hình và động học của đối tượng xuyên suốt chuỗi khung hình nhằm thiết lập quỹ đạo, từ đó tổng hợp và phân cụm các quỹ đạo này để ước lượng số lượng thực thể. Phương pháp dựa trên phát hiện đang là phương pháp phổ biến trong bài toán đếm nhờ các kết quả tốt của quá trình phát hiện và theo dõi phương tiện. Tuy nhiên, yêu cầu tính toán sẽ lớn hơn so với các phương pháp trước và cần chi phí cao (GPU) để triển khai trên các thiết bị (Shokri et al., 2025).

3 Hướng tiếp cận dự kiến

3.1 Các vấn đề của bài toán sau khi khảo sát các công trình liên quan

3.2 Hướng tiếp cận của đề tài

Để giải quyết các vấn đề trên, đề tài lựa chọn mô hình YOLOv8n làm bộ phát hiện phương tiện. YOLOv8n là phiên bản có kích thước nhỏ của họ YOLOv8, cho phép đạt tốc độ suy luận cao trong khi vẫn duy trì độ chính xác phù hợp cho các ứng dụng giao thông thời gian thực. Mô hình được fine-tune trên bộ dữ liệu UA-DETRAC nhằm nâng cao khả năng nhận diện các loại phương tiện xuất hiện trong môi trường giao thông thực tế.

Bên cạnh đó, đề tài sử dụng thuật toán BYTE để thực hiện theo dõi đa đối tượng. Khác với nhiều phương pháp theo dõi truyền thống chỉ sử dụng các phát hiện có độ tin cậy cao, BYTE tận dụng cả các phát hiện có độ tin cậy thấp trong quá trình liên kết đối tượng giữa các khung hình. Nhờ đó, thuật toán giúp giảm hiện tượng mất dấu, hạn chế thay đổi định danh đối tượng và nâng cao độ chính xác của quá trình đếm phương tiện.

Hệ thống đề xuất bao gồm ba giai đoạn chính: phát hiện phương tiện bằng YOLOv8n, theo dõi phương tiện bằng BYTE và đếm phương tiện dựa trên quỹ đạo di chuyển của đối tượng qua vùng hoặc đường đếm được xác định trước. Cách tiếp cận này hướng tới mục tiêu cân bằng giữa độ chính xác và tốc độ xử lý, đáp ứng yêu cầu giám sát giao thông tự động và cung cấp dữ liệu gần thời gian thực cho các ứng dụng trong ITS.

3.3 Mô hình YOLOv8

YOLOv8 được Ultralytics phát hành vào ngày 10 tháng 1 năm 2023, mang đến những cải tiến đáng kể về độ chính xác và tốc độ xử lý so với các phiên bản trước đó. Kế thừa những ưu điểm của các thế hệ YOLO trước, YOLOv8 được bổ sung nhiều đặc điểm và tối ưu hóa mới trong kiến trúc mạng, giúp nâng cao khả năng trích xuất đặc trưng và hiệu quả phát hiện đối tượng. Nhờ những cải tiến này, YOLOv8 trở thành một lựa chọn phù hợp cho nhiều bài toán phát hiện đối tượng trong các ứng dụng thị giác máy tính khác nhau.

Về mặt kiến trúc, YOLOv8 được xây dựng dựa trên ba thành phần chính: Backbone, Neck và Detection Head. Thành phần Backbone sử dụng kiến trúc CSPDarknet cải tiến đảm nhiệm vai trò trích xuất đặc trưng đa tỉ lệ từ ảnh đầu vào thông qua các lớp tích chập được tối ưu hóa nhằm học các đặc trưng phân cấp bao gồm đặc trưng mức thấp như

kết cấu, cạnh và đặc trưng ngữ nghĩa cấp cao. Các đặc trưng này sau đó được chuyển đến thành phần Neck để thực hiện hợp nhất thông tin đa tỉ lệ. Thành phần Neck sử dụng kiến trúc PANet cải tiến giúp tăng cường khả năng trao đổi thông tin giữa các mức đặc trưng khác nhau, từ đó nâng cao hiệu quả phát hiện đối tượng có kích thước khác nhau. Thành phần Head chịu trách nhiệm sinh ra các dự đoán cuối cùng, bao gồm tọa độ hộp bao, độ tin cậy, và nhãn lớp. Một cải tiến đáng chú ý của YOLOv8 là việc áp dụng cơ chế anchor-free thay cho cơ chế anchor-based được sử dụng trong các phiên bản YOLO trước. Cách tiếp cận này giúp đơn giản quá trình dự đoán, giảm số lượng tham số và cải thiện khả năng thích ứng của mô hình đối với đối tượng có kích thước khác nhau (Yaseen, 2024).

Ngoài những cải tiến về kiến trúc, YOLOv8 còn được tối ưu hóa nhằm đạt sự cân bằng giữa độ chính xác và tốc độ xử lý. Ultralytics cung cấp nhiều biến thể khác nhau bao gồm YOLOv8n, YOLOv8s, YOLOv8m, YOLOv8l và YOLOv8x, cho phép người dùng lựa chọn mô hình phù hợp với yêu cầu về hiệu năng và tài nguyên phần cứng.

3.3.1 Biến thể YOLOv8n

Trong nghiên cứu này, biến thể YOLOv8n được lựa chọn làm mô hình phát hiện đối tượng chính. YOLOv8n là phiên bản có quy mô nhỏ nhất trong họ YOLOv8, được thiết kế nhằm giảm yêu cầu về tài nguyên tính toán trong khi vẫn duy trì hiệu năng phát hiện đối tượng ở mức cao. Với số lượng tham số ít hơn so với các biến thể còn lại, YOLOv8n phù hợp cho các hệ thống nhúng, thiết bị biên và các ứng dụng yêu cầu xử lý thời gian thực.

YOLOv8n đạt được kích thước mô hình nhỏ gọn thông qua việc sử dụng các lớp tích chập được tối ưu hóa và giảm số lượng tham số trong mạng. Kích thước mô hình chỉ khoảng 2 MB ở định dạng INT8 và khoảng 3.8 MB ở định dạng FP32, giúp giảm yêu cầu về bộ nhớ lưu trữ và bộ nhớ truy cập trong quá trình suy luận. Đặc điểm này khiến YOLOv8n trở thành lựa chọn phù hợp cho các thiết bị nhúng, hệ thống IoT và các nền tảng di động có giới hạn về năng lượng và tài nguyên phần cứng (Yaseen, 2024).

Ngoài ra, YOLOv8n hỗ trợ triển khai trên nhiều nền tảng tăng tốc suy luận như ONNX Runtime và TensorRT, cho phép tận dụng hiệu quả tài nguyên phần cứng và giảm độ trễ khi xử lý thời gian thực (Yaseen, 2024).

Nhờ sự kết hợp giữa kiến trúc gọn nhẹ, tốc độ cao và khả năng triển khai linh hoạt, YOLOv8n được lựa chọn làm mô hình nền tảng cho hệ thống phát hiện đối tượng được đề xuất trong nghiên cứu này.

3.4 Thuật toán BYTE

Thuật toán BYTE được đề xuất trong (Zhang et al., 2022) là một phương pháp liên kết dữ liệu (data association) trong quá trình theo dõi đối tượng. BYTE khác các thuật toán trước nó, vốn chỉ giữ lại các hộp phát hiện với độ tin cậy cao, trao các hộp phát hiện độ tin cậy thấp cơ hội sau khi đã xem xét các hộp độ tin cậy cao. Cách hoạt động như sau: đầu tiên, thuật toán nhận vào hộp phát hiện được dự đoán trong khung hình hiện tại và chia nó thành hai phần bằng cách lấy ngưỡng trên độ tin cậy; các hộp có độ tin cậy cao được đem liên kết với các vết theo dõi được dự đoán theo Kalman Filter từ khung hình trước bằng độ đo tương đồng 1 qua Thuật toán Hungarian; sau đó, các hộp có độ tin cậy thấp được đem liên kết với các vết theo dõi còn lại theo độ đo tương đồng 2; cuối cùng, các hộp có độ tin cậy cao chưa được liên kết sẽ được tạo thành các vết theo dõi

mới (Zhang et al., 2022). Đây là một phương pháp liên kết dữ liệu đơn giản, hiệu quả và rất tổng quát. Ta có thể dùng bất cứ độ đo nào trong hai liên kết như IoU hay Re-ID.

4 Thí nghiệm

4.1 Thiết lập thực nghiệm

4.1.1 Tập dữ liệu

Nghiên cứu này sử dụng tập dữ liệu UA-DETRAC (University at Albany DETection and TRACKing) làm cơ sở chuẩn đối sánh. Quy mô của tập dữ liệu bao gồm 100 chuỗi video được chọn từ hơn 10 giờ từ camera ghi lại các bối cảnh giao thông thực tế ở 24 vị trí khác nhau với đa dạng mẫu và điều kiện giao thông bao gồm cao tốc đô thị, nút giao thông, ngã ba chữ T (Wen et al., 2020). Các video này được ghi lại với 25 khung hình/giây (FPS) với định dạng JPEG và độ phân giải 960×540 (Wen et al., 2020).

Hơn 140,000 khung hình được chú thích (annotated) thủ công với hơn 8,250 phương tiện và tổng cộng 1.21 triệu hộp bao được gán nhãn. Mỗi mẫu dữ liệu chứa thông tin tọa độ của các hộp bao nhằm định vị chính xác các phương tiện. Bên cạnh đó, mỗi đối tượng trong mẫu được mô tả chi tiết thông qua các thuộc tính bao gồm: phân lớp phương tiện (ô tô, xe buýt, xe tải nhỏ và các loại khác), bối cảnh chiếu sáng (nhiều mây, ban đêm, trời nắng, trời mưa), phạm vi kích thước (nhỏ, trung bình, lớn), tỷ lệ che khuất (không che khuất, che khuất một phần, che khuất nhiều) và tỷ lệ nằm ngoài khung hình (Wen et al., 2020). Nhằm phục vụ cho quá trình đánh giá mô hình, tập dữ liệu được phân hoạch thành hai tập con độc lập: tập huấn luyện (train) chứa 60 chuỗi video với xấp xỉ 84.000 khung hình, và tập kiểm tra (test) bao gồm 40 chuỗi video với 56.000 khung hình (Wen et al., 2020).

4.1.2 Các độ đo đánh giá

Phát hiện Để đánh giá chất lượng của mô hình phát hiện đối tượng, các độ đo được sử dụng bao gồm Precision, Recall, F1-score, mAP@50 và mAP@50-95. Các độ đo này phản ánh khả năng phát hiện, phân loại và định vị đối tượng của mô hình trên tập dữ liệu đánh giá.

Precision đánh giá tỷ lệ các đối tượng được mô hình dự đoán là đúng trên tổng số các đối tượng được dự đoán. Chỉ số này phản ánh mức độ tin cậy của các dự đoán do mô hình tạo ra và được tính như sau:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (1)$$

trong đó, TP (True Positives) là số lượng đối tượng được phát hiện đúng và FP (False Positives) là số lượng đối tượng được dự đoán nhưng không tồn tại trong thực tế.

Recall đánh giá khả năng phát hiện đầy đủ các đối tượng có trong ảnh. Chỉ số này được tính bằng tỷ lệ số đối tượng được phát hiện đúng trên tổng số đối tượng thực tế:

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (2)$$

trong đó, FN (False Negatives) là số lượng đối tượng thực tế nhưng bị mô hình bỏ sót. Recall cao cho thấy mô hình có khả năng phát hiện được phần lớn các đối tượng trong dữ liệu.

F1-score là trung bình điều hòa của Precision và Recall, được sử dụng để đánh giá sự cân bằng giữa độ chính xác và khả năng phát hiện của mô hình:

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (3)$$

Giá trị F1-score càng cao cho thấy mô hình đạt được sự cân bằng tốt giữa Precision và Recall.

Trong bài toán phát hiện đối tượng, đường cong Precision–Recall (PR) được xây dựng bằng cách thay đổi ngưỡng confidence của mô hình. Từ đường cong này, diện tích dưới đường cong được sử dụng để tính Average Precision (AP):

$$AP = \int_0^1 P(R) dR, \quad (4)$$

trong đó $P(R)$ là giá trị Precision tương ứng với Recall R . AP phản ánh đồng thời khả năng phát hiện và phân loại đối tượng của mô hình trên một lớp cụ thể.

Đối với bài toán nhiều lớp, chỉ số Mean Average Precision (mAP) được tính bằng giá trị trung bình của AP trên tất cả các lớp:

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N AP_i, \quad (5)$$

trong đó N là số lớp đối tượng và AP_i là Average Precision của lớp thứ i .

Chỉ số mAP@50 được tính tại ngưỡng IoU bằng 0.5, nghĩa là một đối tượng được xem là phát hiện đúng nếu độ chồng lấp giữa hộp dự đoán và hộp thực tế đạt ít nhất 50% diện tích tổng quát của mô hình.

Để đánh giá chặt chẽ hơn chất lượng định vị, chỉ số mAP@50–95 được sử dụng. Độ đo này được tính bằng giá trị trung bình của AP tại các ngưỡng IoU từ 0.5 đến 0.95 với bước nhảy 0.05:

$$\text{mAP@50–95} = \frac{1}{10} \sum_{\text{IoU} \in \{0.50, 0.55, \dots, 0.95\}} AP_{\text{IoU}}. \quad (6)$$

Do được tính trên nhiều ngưỡng IoU khác nhau, mAP@50–95 phản ánh toàn diện hơn khả năng phát hiện và định vị đối tượng của mô hình.

Theo dõi Để đánh giá chất lượng của phương pháp theo dõi đa đối tượng, các độ đo được sử dụng bao gồm tập độ đo CLEAR (MOTA, MOTP), độ đo nhận dạng IDF1, và độ đo bậc cao HOTA.

Tập độ đo CLEAR đánh giá hệ thống thông qua hai khía cạnh chính: độ chính xác định vị và độ chính xác theo dõi. Độ chuẩn xác MOT (Multiple Object Tracking Precision, MOTP) thể hiện khả năng ước lượng vị trí chính xác của đối tượng độc lập với khả năng nhận dạng. MOTP được tính bằng trung bình sai số vị trí của các cặp đối tượng được khớp thành công:

$$\text{MOTP} = \frac{\sum_{i,t} d_t^i}{\sum_t c_t}, \quad (7)$$

trong đó, d_t^i là sai số khoảng cách giữa dự đoán và thực tế của đối tượng thứ i tại khung hình t , và c_t là số lượng đối tượng được khớp tại khung hình t (Bernardin & Stiefelhausen, 2008).

Độ chính xác MOT (Multiple Object Tracking Accuracy, MOTA) đánh giá độ chính xác tổng thể trong việc phát hiện và duy trì quỹ đạo của đối tượng. MOTA tổng hợp ba loại lỗi: bỏ sót (misses), nhận diện sai (false positives) và sai số ghép cặp/nhảy ID (mismatches):

$$\text{MOTA} = 1 - \frac{\sum_t (m_t + fp_t + mme_t)}{\sum_t g_t}, \quad (8)$$

trong đó, m_t là số lượng bỏ sót, fp_t là số nhận diện sai, mme_t là số lần nhảy ID, và g_t là tổng số đối tượng thực tế tại khung hình t (Bernardin & Stiefelhagen, 2008).

Trong khi MOTA chú trọng nhiều vào độ chính xác phát hiện ở từng khung hình rời rạc, IDF1 (Identification F1-score) tập trung đánh giá khả năng duy trì danh tính (ID) cố định của đối tượng qua thời gian dài. IDF1 tính toán tỷ lệ các phát hiện được gán đúng danh tính trên tổng số trung bình của các phát hiện thực tế và dự đoán:

$$\text{IDF}_1 = \frac{2 \times \text{IDTP}}{2 \cdot \text{IDTP} + \text{IDFP} + \text{IDFN}}, \quad (9)$$

trong đó, IDTP (Identification True Positives) là số lượng hộp bao dự đoán đúng cả vị trí và danh tính, IDFP (Identification False Positives) là số hộp bao dự đoán sai danh tính hoặc vị trí, và IDFN (Identification False Negatives) là số hộp bao thực tế bị bỏ sót hoặc gán nhầm danh tính (Ristani, Solera, Zou, Cucchiara, & Tomasi, 2016).

HOTA là một độ đo mới nhằm khắc phục hạn chế của cả MOTA và IDF1 bằng cách cân bằng một cách rõ ràng giữa độ chính xác phát hiện (Detection), liên kết (Association) và định vị (Localization) thành một chỉ số thống nhất duy nhất. Tại một ngưỡng định vị α , HOTA được định nghĩa là trung bình nhân của điểm phát hiện và điểm liên kết:

$$\text{DetA}_\alpha = \frac{|\text{TP}|}{|\text{TP}| + |\text{FN}| + |\text{FP}|}, \quad (10)$$

$$\text{AssA}_\alpha = \frac{1}{|\text{TP}|} \sum_{c \in \text{TP}} \mathcal{A}(c), \quad (11)$$

$$\mathcal{A}(c) = \frac{|\text{TPA}(c)|}{|\text{TPA}(c)| + |\text{FNA}(c)| + |\text{FPA}(c)|}, \quad (12)$$

$$\text{HOTA}_\alpha = \sqrt{\frac{\sum_{c \in \text{TP}} \mathcal{A}(c)}{|\text{TP}| + |\text{FN}| + |\text{FP}|}} = \sqrt{\text{DetA}_\alpha \cdot \text{AssA}_\alpha}, \quad (13)$$

trong đó, TP, FN, FP lần lượt là số lượng True Positives, False Negatives, và False Positives trong phát hiện được tính trên ngưỡng α ; $\text{TPA}(c)$, $\text{FNA}(c)$, $\text{FPA}(c)$ lần lượt là số lượng phát hiện được gán đúng ID của c , số lượng phát hiện là c nhưng bị gán sai ID hoặc bị bỏ sót, và số lượng phát hiện bị gán sai thành ID của c . Hàm $\mathcal{A}(c)$ thể hiện độ chính xác liên kết (Association Accuracy) đối với mỗi True Positive c (Luiten et al., 2020).

Để phản ánh chính xác cả khả năng định vị, điểm HOTA tổng quát được tính bằng cách lấy tích phân (thường được xấp xỉ bằng giá trị trung bình) trên nhiều ngưỡng định vị α khác nhau (ví dụ từ 0.05 đến 0.95):

$$\text{HOTA} = \int_0^1 \text{HOTA}_\alpha d\alpha \approx \frac{1}{19} \sum_{\alpha \in \{0.05, 0.1, \dots, 0.95\}} \text{HOTA}_\alpha. \quad (14)$$

Tương tự ta có thể định nghĩa DetA và AssA. DetA thể hiện độ chính xác phát hiện và AssA thể hiện khả năng định danh nhất quán của bộ theo dõi. Do đó, HOTA có sự cân bằng đánh giá giữa phát hiện và liên kết.

4.1.3 Fine-tuning mô hình YOLOv8n

Mô hình YOLOv8n được khởi tạo từ trọng số tiền huấn luyện trên tập dữ liệu COCO và được fine-tuning trên bộ dữ liệu UA-DETRAC. Bộ dữ liệu được chia theo tỷ lệ 80% cho tập huấn luyện và 20% cho tập xác thực nhằm đánh giá khả năng tổng quát hóa của mô hình trên dữ liệu chưa được sử dụng trong quá trình huấn luyện. Trong quá trình fine-tuning, 10 lớp đầu tiên của mạng được đóng băng nhằm giữ lại các đặc trưng mức thấp đã được học từ tập dữ liệu COCO, trong khi các lớp còn lại được cập nhật trọng số để thích nghi với đặc trưng của bộ dữ liệu UA-DETRAC.

Các tham số huấn luyện được thiết lập như sau:

- Số epoch: 20.
- Kích thước ảnh đầu vào: 640×640 pixel.
- Batch size: 64.
- Thiết bị huấn luyện: Google Colab với GPU NVIDIA Tesla T4.
- Trọng số khởi tạo: YOLOv8n được tiền huấn luyện trên tập dữ liệu COCO.
- Số lớp được đóng băng: 10 lớp đầu tiên.

4.1.4 Tham số cho bộ theo dõi

Hai thuật toán theo dõi được sử dụng trong nghiên cứu này là SORT (đóng vai trò đường cơ sở) và ByteTrack. Các tham số của SORT (ngoại trừ `high_conf_det_threshold`) và BYTE được trình bày trong Bảng 1. Để đảm bảo tính công bằng trong so sánh, các tham số tương ứng của hai thuật toán được thiết lập ở mức tương đương khi có thể. Việc chuẩn hóa cấu hình này nhằm hạn chế ảnh hưởng của quá trình tinh chỉnh tham số đến kết quả thực nghiệm, từ đó phản ánh rõ hơn sự khác biệt xuất phát từ cơ chế liên kết đối tượng của từng thuật toán. Kỳ vọng là BYTE sẽ đạt hiệu năng theo dõi tốt hơn nhờ khả năng khai thác cả các phát hiện có độ tin cậy thấp trong quá trình liên kết, trong khi SORT chỉ sử dụng các phát hiện vượt qua ngưỡng tin cậy đã định.

Tham số `confidence_threshold` để loại bỏ các phát hiện cực kì thấp để giảm số lượng tính toán nhưng vẫn giữ độ hiệu quả. Giá trị 0.2 được tham khảo từ Hình 3 và Hình 4 khi Recall lớn (khoảng 0.8) trong khi độ chuẩn xác ở các lớp ở mức ổn (gần 0.5). Tham số `high_conf_det_threshold` ngưỡng tin cậy cao có giá trị là 0.494 được tham khảo từ Hình 6 khi điểm F1 đạt cực đại cho thấy sự cân bằng tốt giữa chuẩn xác và bỏ sót. Tham số `track_activation_threshold` được lựa chọn bằng với `high_conf_det_threshold` theo đúng thuật toán BYTE. Tham số `lost_track_buffer` là 75 (tương ứng là 3 giây) để thuật toán tránh quên đi các ID cũ khi phương tiện bị che khuất hay chồng lấp. Tham số `minimum_consecutive_frames` được chọn là 2 để tránh nhiễu lúc phát hiện. Tham số `minimum_iou_threshold` là ngưỡng để các hộp phát hiện được liên kết với vết theo dõi qua dự đoán của Kalman Filter. Tham số được chọn với giá trị nhỏ 0.1 để ổn định với các phương tiện di chuyển nhanh (như trên cao tốc) hay di chuyển sát camera.

Bảng 1: Các siêu tham số cho thuật toán SORT và BYTE

Tên tham số	Giá trị	Mô tả
<code>confidence_threshold</code>	0.2	Ngưỡng độ tin cậy của bộ phát hiện trước khi liên kết dữ liệu
<code>high_conf_det_threshold</code>	0.494	Ngưỡng độ tin cậy để phát hiện thành phần cao và thấp
<code>track_activation_threshold</code>	0.494	Ngưỡng độ tin cậy để tạo thành vết theo dõi mới
<code>minimum_iou_threshold</code>	0.1	Ngưỡng trong quá trình liên kết dữ liệu bằng độ đo tương đồng IoU
<code>lost_track_buffer</code>	75	Số lượng khung hình nhớ một ID khi bị mất dấu
<code>frame_rate</code>	25	Tốc độ khung hình
<code>minimum_consecutive_frames</code>	2	Số lượng khung hình xuất hiện để được cấp ID

4.2 Kết quả thực nghiệm

4.2.1 Kết quả quá trình huấn luyện YOLOv8n


Phân phối nhân, vị trí và kích thước đối tượng Hình 1 trình bày phân bố số lượng mẫu theo từng lớp đối tượng, đồng thời thể hiện phân bố vị trí tâm và kích thước của các hộp bao trong tập dữ liệu. Kết quả cho thấy số lượng mẫu giữa các lớp có sự chênh lệch đáng kể. Trong đó, lớp xe hơi (car) chiếm tỷ lệ lớn nhất với 402 630 mẫu, tiếp theo là lớp xe tải nhỏ (van) với 46 035 mẫu và lớp xe buýt (bus) với 22 153 mẫu. Lớp khác (others) chỉ gồm 2 901 mẫu, chiếm tỷ lệ rất nhỏ trong toàn bộ tập dữ liệu. Điều này cho thấy tập dữ liệu tồn tại hiện tượng mất cân bằng giữa các lớp, trong đó lớp xe hơi áp đảo về số lượng so với các lớp còn lại.

Biểu đồ phân bố vị trí tâm của các hộp bao cho thấy các đối tượng xuất hiện trên nhiều vị trí khác nhau trong ảnh, tuy nhiên mật độ phân bố không đồng đều. Phần lớn đối tượng tập trung ở vùng trung tâm theo chiều ngang và nửa dưới của khung hình. Đặc điểm này phản ánh bối cảnh thu thập dữ liệu giao thông, khi các phương tiện thường xuất hiện trên mặt đường và nằm trong vùng quan sát chính của camera. Mặc dù mật độ cao tập trung ở khu vực trung tâm, dữ liệu vẫn bao phủ tương đối đầy đủ các vị trí trong ảnh, góp phần nâng cao khả năng tổng quát hóa của mô hình.

Đối với kích thước đối tượng, biểu đồ phân bố chiều rộng và chiều cao của hộp bao cho thấy đa số đối tượng có kích thước nhỏ. Các giá trị chiều rộng chủ yếu tập trung trong khoảng từ 0,03 đến 0,12, trong khi chiều cao tập trung khoảng từ 0,04 đến 0,15 (chuẩn hóa theo kích thước ảnh). Số lượng đối tượng giảm dần khi kích thước tăng lên, tạo thành dạng phân bố đuôi dài. Điều này cho thấy phần lớn phương tiện được ghi nhận ở khoảng cách tương đối xa so với camera, khiến chúng chỉ chiếm một phần nhỏ diện tích ảnh.

Tổng thể, tập dữ liệu có ba đặc điểm nổi bật: sự mất cân bằng về số lượng mẫu giữa

các lớp, sự tập trung vị trí xuất hiện của đối tượng ở vùng trung tâm và nửa dưới ảnh, cùng với tỷ lệ lớn các đối tượng có kích thước nhỏ.




Hình 1: Phân bố nhãn, vị trí tâm và kích thước hộp bao của các đối tượng trong tập dữ liệu.

Kết quả hội tụ của mô hình Hình 2 trình bày sự thay đổi của các hàm mất mát và các chỉ số đánh giá trong quá trình fine-tuning mô hình YOLOv8n trên tập huấn luyện và tập xác thực. Nhìn chung, các hàm mất mát trên tập huấn luyện đều có xu hướng giảm dần theo số epoch. Mức giảm diễn ra tương đối nhanh ở những epoch đầu và chậm dần ở giai đoạn cuối, cho thấy mô hình từng bước học được các đặc trưng quan trọng của dữ liệu và hội tụ ổn định trong quá trình huấn luyện.

Tương tự, các hàm mất mát trên tập xác thực cũng có xu hướng giảm theo thời gian huấn luyện. Mặc dù xuất hiện một số dao động ở các epoch đầu, các giá trị này dần ổn định ở những epoch cuối. Sự khác biệt giữa các đường cong trên tập huấn luyện và tập xác thực không đáng kể, cho thấy mô hình chưa xuất hiện dấu hiệu quá khớp nghiêm trọng và vẫn duy trì khả năng tổng quát hóa tốt trên dữ liệu chưa quan sát.

Đối với các chỉ số đánh giá, Precision, Recall, mAP@0.5 và mAP@0.5:0.95 đều có xu hướng tăng trong quá trình huấn luyện. Các chỉ số này tăng nhanh ở giai đoạn đầu, sau đó dao động nhẹ và đạt trạng thái tương đối ổn định ở các epoch cuối. Mặc dù một số thời điểm ghi nhận sự sụt giảm nhỏ, hiệu năng tổng thể của mô hình vẫn được cải thiện đáng kể so với thời điểm bắt đầu huấn luyện. Điều này cho thấy khả năng phát hiện và định vị đối tượng của mô hình ngày càng chính xác hơn sau quá trình fine-tuning.

Nhìn chung, mô hình YOLOv8n đạt trạng thái hội tụ ổn định trên cả tập huấn luyện và tập xác thực. Sự suy giảm của các hàm mất mát cùng với sự cải thiện của các chỉ số đánh giá cho thấy mô hình đã học được các đặc trưng hiệu quả từ tập dữ liệu và đạt được hiệu năng phát hiện đối tượng tốt ở giai đoạn cuối của quá trình huấn luyện.



Hình 2: Kết quả huấn luyện và xác thực của mô hình YOLOv8n trong quá trình fine-tuning


Đánh giá hiệu năng phát hiện đối tượng trên tập xác thực

Đường cong Precision Hình 3 trình bày sự thay đổi của chỉ số Precision theo các ngưỡng confidence khác nhau. Kết quả cho thấy Precision có xu hướng tăng dần khi ngưỡng confidence tăng. Ở các ngưỡng confidence thấp, mô hình giữ lại nhiều dự đoán hơn, bao gồm cả các dự đoán có độ tin cậy thấp, dẫn đến số lượng dự đoán sai tương đối lớn và làm giảm giá trị Precision. Khi confidence tăng, các dự đoán có độ tin cậy thấp dần được loại bỏ, giúp giảm số lượng dự đoán sai và nâng cao độ chính xác của mô hình.

Đối với toàn bộ các lớp, đường cong Precision tăng ổn định và đạt giá trị cực đại bằng 1,00 tại ngưỡng confidence khoảng 0,993. Điều này cho thấy khi chỉ giữ lại các dự đoán có độ tin cậy rất cao, mô hình hầu như không tạo ra các dự đoán dương tính giả.

Xét theo từng lớp đối tượng, lớp xe hơi đạt Precision cao nhất trên hầu hết các ngưỡng confidence và duy trì mức tăng ổn định trong toàn bộ dải giá trị. Lớp xe buýt cũng cho thấy hiệu năng tốt với đường cong nằm ở mức cao và ít biến động. Trong khi đó, lớp xe tải nhỏ và lớp khác có Precision thấp hơn, đặc biệt ở các ngưỡng confidence thấp, phản ánh mức độ khó cao hơn trong việc phân biệt các đối tượng thuộc hai lớp này. Tuy nhiên, khi confidence tăng, Precision của các lớp đều được cải thiện đáng kể và tiến gần đến giá trị tối đa.

Nhìn chung, đường cong Precision cho thấy mô hình có khả năng loại bỏ hiệu quả các dự đoán sai khi tăng ngưỡng confidence, đồng thời duy trì độ chính xác cao đối với các đối tượng được phát hiện.



Hình 3: Đường cong Precision theo ngưỡng confidence

Đường cong Recall Hình 4 trình bày sự thay đổi của chỉ số Recall theo các ngưỡng confidence khác nhau. Kết quả cho thấy Recall có xu hướng giảm dần khi confidence tăng. Ở các ngưỡng confidence thấp, mô hình giữ lại phần lớn các dự đoán nên số lượng đối tượng bị bỏ sót ở mức thấp, nhờ đó Recall đạt giá trị cao. Khi confidence tăng, các dự đoán có độ tin cậy thấp dần bị loại bỏ, làm số lượng đối tượng không được phát hiện tăng lên và khiến Recall giảm theo.


Đối với toàn bộ các lớp, Recall đạt giá trị lớn nhất khoảng 0,90 tại ngưỡng confidence bằng 0. Khi confidence tiếp tục tăng, Recall giảm tương đối chậm ở giai đoạn đầu và giảm nhanh hơn tại các ngưỡng confidence cao. Điều này phản ánh sự đánh đổi giữa khả năng phát hiện đầy đủ đối tượng và độ tin cậy của các dự đoán.

Xét theo từng lớp đối tượng, lớp xe buýt duy trì Recall cao nhất trên hầu hết các ngưỡng confidence và có tốc độ suy giảm chậm hơn so với các lớp còn lại. Lớp xe hơi đạt Recall ở mức tương đối cao và ổn định trong phần lớn khoảng confidence. Trong khi đó, lớp xe tải nhỏ có Recall thấp hơn và giảm nhanh hơn khi confidence tăng. Lớp khác cho thấy Recall thấp nhất trong toàn bộ dải confidence, phản ánh mức độ khó khăn lớn hơn trong việc phát hiện chính xác các đối tượng thuộc lớp này.

Nhìn chung, đường cong Recall cho thấy mô hình có khả năng phát hiện tương đối tốt các đối tượng ở các ngưỡng confidence thấp. Tuy nhiên, khi tăng confidence nhằm nâng cao độ tin cậy của các dự đoán, số lượng đối tượng bị bỏ sót cũng tăng lên, dẫn đến sự suy giảm của Recall. Đây là xu hướng thường gặp trong các bài toán phát hiện đối tượng và thể hiện sự cân bằng giữa Recall và Precision của mô hình.

Đường cong Precision–Recall Hình 5 trình bày đường cong Precision–Recall của mô hình đối với từng lớp đối tượng. Kết quả cho thấy các đường cong có sự khác biệt đáng kể giữa các lớp, phản ánh mức độ khó khăn khác nhau trong quá trình phát hiện và phân loại đối tượng. Đối với toàn bộ các lớp, mô hình đạt giá trị mAP@0.5 bằng 0.769, cho thấy khả năng phát hiện đối tượng ở mức tương đối tốt trên tập xác thực.

Xét theo từng lớp, lớp xe buýt đạt giá trị AP cao nhất với 0.941. Đường cong Precision–Recall của lớp này nằm gần góc trên bên phải của đồ thị, cho thấy mô hình



Hình 4: Đường cong Recall theo ngưỡng confidence

duy trì được đồng thời Precision và Recall ở mức cao trên phần lớn miền giá trị. Lớp xe hơi cũng đạt kết quả tốt với AP bằng 0.919, chỉ thấp hơn không đáng kể so với lớp xe buýt.


Trong khi đó, lớp xe tải nhỏ đạt AP bằng 0.731. Mặc dù vẫn duy trì được Precision cao ở các mức Recall thấp và trung bình, Precision giảm nhanh hơn khi Recall tăng cao. Lớp khác có AP thấp nhất với giá trị 0.485 và đường cong nằm xa góc trên bên phải của đồ thị hơn so với các lớp còn lại. Kết quả này cho thấy mô hình gặp nhiều khó khăn hơn trong việc phát hiện và phân biệt các đối tượng thuộc lớp này, có thể do số lượng mẫu huấn luyện hạn chế và sự đa dạng lớn về đặc trưng của đối tượng.

Nhìn chung, đường cong Precision-Recall cho thấy mô hình đạt hiệu năng phát hiện rất tốt đối với các lớp xe hơi và xe buýt, trong khi hiệu năng đối với lớp xe tải nhỏ và đặc biệt là lớp khác còn thấp hơn. Sự chênh lệch này phản ánh ảnh hưởng của sự mất cân bằng dữ liệu giữa các lớp và là một trong những yếu tố cần được xem xét để tiếp tục cải thiện hiệu năng của mô hình.

Đường cong F1-score Hình 6 trình bày sự thay đổi của chỉ số F1-score theo các ngưỡng confidence khác nhau. Kết quả cho thấy F1-score tăng nhanh khi confidence tăng từ 0 đến khoảng 0,2. Ở các ngưỡng confidence thấp, mô hình giữ lại nhiều dự đoán có độ tin cậy thấp, làm giảm độ chính xác của kết quả phát hiện mặc dù khả năng phát hiện đối tượng vẫn được duy trì ở mức cao. Khi confidence tiếp tục tăng, các dự đoán kém tin cậy dần được loại bỏ, giúp cải thiện sự cân bằng giữa Precision và Recall, từ đó F1-score tăng lên và duy trì ở mức tương đối ổn định trong một khoảng confidence rộng.

Tuy nhiên, khi confidence tăng đến các giá trị cao, F1-score bắt đầu giảm đáng kể. Nguyên nhân là do nhiều đối tượng thực sự cũng bị loại bỏ khỏi kết quả dự đoán, làm Recall suy giảm nhanh hơn mức cải thiện của Precision. Điều này cho thấy việc lựa chọn confidence quá cao có thể làm giảm hiệu quả phát hiện tổng thể của mô hình.

Đối với toàn bộ các lớp, F1-score đạt giá trị cực đại khoảng 0,74 tại ngưỡng confidence xấp xỉ 0,494. Đây là ngưỡng mang lại sự cân bằng tốt nhất giữa Precision và Recall, đồng thời phù hợp để sử dụng trong quá trình suy luận và đánh giá mô hình.



Hình 5: Đường cong Precision–Recall của mô hình


Xét theo từng lớp đối tượng, lớp xe buýt đạt F1-score cao nhất trên phần lớn miền confidence và duy trì giá trị ổn định trong khoảng confidence rộng, cho thấy mô hình có khả năng phát hiện và phân loại lớp đối tượng này tốt nhất. Lớp xe hơi cũng đạt kết quả cao và chỉ thấp hơn không đáng kể so với lớp xe buýt. Trong khi đó, lớp xe tải nhỏ có F1-score thấp hơn và giảm nhanh hơn ở các ngưỡng confidence cao. Lớp khác đạt F1-score thấp nhất trong toàn bộ dải confidence, phản ánh những khó khăn của mô hình trong việc nhận dạng và phân biệt các đối tượng thuộc lớp này.

Nhìn chung, đường cong F1-score cho thấy mô hình đạt hiệu năng tốt nhất khi confidence ở mức trung bình. Kết quả này phù hợp với xu hướng quan sát được từ các đường cong Precision và Recall, đồng thời khẳng định mô hình có khả năng duy trì sự cân bằng hợp lý giữa độ chính xác và khả năng phát hiện đối tượng trên tập dữ liệu nghiên cứu.

Ma trận nhầm lẫn chuẩn hóa Hình 7 trình bày ma trận nhầm lẫn chuẩn hóa của mô hình trên tập dữ liệu xác thực. Các giá trị trên đường chéo chính phản ánh tỷ lệ đối tượng được phân loại đúng của từng lớp. Kết quả cho thấy lớp xe buýt đạt tỷ lệ nhận dạng đúng cao nhất với giá trị khoảng 0,93, tiếp theo là lớp xe hơi với 0,87. Trong khi đó, lớp xe tải nhỏ đạt khoảng 0,68 và lớp khác chỉ đạt khoảng 0,32. Điều này cho thấy mô hình hoạt động hiệu quả đối với các lớp xe buýt và xe hơi, nhưng vẫn gặp nhiều khó khăn hơn khi nhận dạng các đối tượng thuộc lớp xe tải nhỏ và lớp khác.

Ngoài các giá trị trên đường chéo chính, một số trường hợp nhầm lẫn giữa các lớp cũng được thể hiện thông qua các phần tử ngoài đường chéo. Đối với lớp xe tải nhỏ, khoảng 19% mẫu thực tế bị dự đoán thành lớp xe hơi. Tương tự, khoảng 18% đối tượng thuộc lớp khác bị nhận dạng nhầm thành xe tải nhỏ và khoảng 15% bị nhận dạng thành xe hơi. Những kết quả này cho thấy sự tương đồng về đặc trưng hình dạng và kích thước giữa các lớp phương tiện khiến mô hình khó phân biệt chính xác trong một số trường hợp.

Bên cạnh đó, ma trận nhầm lẫn còn cho thấy sự xuất hiện của các trường hợp nhầm lẫn với nền. Khoảng 10% đối tượng xe hơi, 6% xe buýt, 12% xe tải nhỏ và 12% đối tượng



Hình 6: Đường cong F1-score theo ngưỡng confidence

thuộc lớp khác bị bỏ sót và được xem như nền trong quá trình đánh giá. Ngược lại, một tỷ lệ tương đối lớn các vùng nền bị mô hình dự đoán thành xe hơi hoặc các lớp phương tiện khác. Hiện tượng này cho thấy mô hình có xu hướng ưu tiên phát hiện các đối tượng phổ biến, đặc biệt là lớp xe hơi, vốn chiếm tỷ lệ lớn trong tập dữ liệu huấn luyện.


Nhìn chung, ma trận nhầm lẫn chuẩn hóa cho thấy mô hình đạt hiệu năng tốt đối với các lớp có số lượng mẫu lớn như xe hơi và xe buýt. Tuy nhiên, hiệu năng đối với lớp xe tải nhỏ và đặc biệt là lớp khác còn hạn chế, phản ánh ảnh hưởng của sự mất cân bằng dữ liệu và sự tương đồng về đặc trưng giữa các lớp đối tượng trong bài toán phát hiện phương tiện giao thông.

Nhận xét tổng kết Kết quả đánh giá trên tập xác thực cho thấy mô hình YOLOv8n sau quá trình fine-tuning đạt hiệu năng phát hiện đối tượng tương đối tốt và hội tụ ổn định. Mô hình nhận dạng hiệu quả các lớp xe hơi và xe buýt, trong khi hiệu năng đối với lớp xe tải nhỏ và lớp khác còn hạn chế hơn do sự mất cân bằng dữ liệu và sự tương đồng giữa các đối tượng. Mặc dù vẫn tồn tại một số trường hợp nhầm lẫn giữa các lớp và với vùng nền, kết quả thu được cho thấy mô hình có khả năng tổng quát hóa tốt và phù hợp cho bài toán phát hiện phương tiện giao thông.

4.2.2 Kết quả trên tập kiểm tra của mô hình YOLOv8n

Bảng 2 trình bày các chỉ số đánh giá hiệu năng của mô hình YOLOv8n trên tập kiểm tra. Trong quá trình đánh giá, ngưỡng confidence được thiết lập là 0.494, tương ứng với giá trị đạt F1-score cao nhất trên tập xác thực. Việc lựa chọn ngưỡng này nhằm cân bằng giữa Precision và Recall, từ đó tối ưu hiệu suất phát hiện của mô hình trên dữ liệu chưa xuất hiện trong quá trình huấn luyện.

Mô hình đạt Precision bằng 0.7352 và Recall bằng 0.5488. Kết quả này cho thấy phần lớn các đối tượng được mô hình dự đoán là chính xác, tuy nhiên mô hình vẫn bỏ sót một số đối tượng trong tập kiểm tra. Đối với các chỉ số đánh giá tổng quát, mô hình đạt mAP@50 bằng 0.5003 và mAP@50–95 bằng 0.3566, cho thấy khả năng phát hiện đối



Hình 7: Ma trận nhầm lẫn chuẩn hóa của mô hình

tượng ở mức tương đối tốt trên dữ liệu kiểm tra.

Để đánh giá hiệu quả của mô hình được đề xuất, kết quả của YOLOv8n được so sánh với YOLOv5nu trên cùng tập kiểm tra. Kết quả cho thấy YOLOv5nu đạt Precision, mAP@50 và mAP@50–95 cao hơn YOLOv8n, trong khi Recall của hai mô hình gần như tương đương. Cụ thể, YOLOv5nu đạt Precision 0.7596, mAP@50 0.5123 và mAP@50–95 0.3682, cao hơn tương ứng 0.0244, 0.0120 và 0.0116 so với YOLOv8n. Trong khi đó, Recall của YOLOv8n đạt 0.5488, nhỉnh hơn không đáng kể so với 0.5484 của YOLOv5nu.

Nhìn chung, cả hai mô hình đều cho khả năng phát hiện đối tượng ở mức tương đối tốt trên tập kiểm tra. Tuy nhiên, YOLOv5nu đạt kết quả tốt hơn ở hầu hết các chỉ số đánh giá, cho thấy mô hình này phù hợp hơn với bộ dữ liệu được sử dụng trong nghiên cứu.

Bảng 2: So sánh kết quả trên tập kiểm tra giữa YOLOv8n và YOLOv5nu

Chỉ số	YOLOv8n	YOLOv5nu
Precision	0.7352	0.7596
Recall	0.5488	0.5484
mAP@50	0.5003	0.5123
mAP@50–95	0.3566	0.3682

4.2.3 Kết quả chọn bộ theo dõi

Bảng 3 trình bày kết quả đánh giá hai thuật toán theo dõi trên tập xác thực. BYTE đạt kết quả cao hơn SORT trên tất cả các độ đo chính, đặc biệt ở AssA và IDF1, cho thấy khả năng duy trì danh tính đối tượng tốt hơn trong quá trình theo dõi. Do đó, BYTE được lựa chọn cho các thí nghiệm đánh giá trên tập kiểm tra ở các phần tiếp theo.

Bảng 3: So sánh kết quả theo dõi của SORT và BYTE trên tập xác thực

Độ đo	YOLO + SORT	YOLO + BYTE
HOTA	68.455	69.633
DetA	66.955	67.588
AssA	70.343	72.072
LocA	87.653	87.669
MOTA	73.978	75.607
MOTP	86.294	86.311
IDF1	79.419	81.483

4.2.4 Kết quả theo dõi trên tập kiểm tra

Sau khi lựa chọn BYTE trên tập xác thực, cấu hình này được sử dụng để đánh giá trên tập kiểm tra. Kết quả trong Bảng 4 cho thấy hệ thống đạt HOTA bằng 60.716 và IDF1 bằng 70.345. Giá trị AssA đạt 62.800 cho thấy khả năng duy trì danh tính đối tượng tương đối ổn định, trong khi DetA đạt 59.184 phản ánh chất lượng phát hiện của mô hình YOLO vẫn là yếu tố ảnh hưởng đáng kể đến hiệu năng theo dõi tổng thể. Ngoài ra, các thông số về độ chuẩn xác định vị MOTP (84.339) và LocA (85.953) cho thấy các hộp bao được gán khá chuẩn xác với phương tiện.


Bảng 4: Kết quả đánh giá quá trình theo dõi trên tập kiểm tra

Độ đo	Giá trị
HOTA	60.716
DetA	59.184
AssA	62.800
LocA	85.953
MOTA	64.676
MOTP	84.334
IDF1	70.345

Hình 8 cho thấy các độ đo HOTA, DetA và AssA có xu hướng giảm khi giá trị ngưỡng α tăng. Trong khoảng từ $\alpha = 0.0$ đến $\alpha = 0.7$, mức suy giảm của các độ đo tương đối nhỏ, cho thấy hệ thống vẫn duy trì được hiệu năng phát hiện và liên kết đối tượng ổn định ở các ngưỡng đánh giá trung bình. Tuy nhiên, từ $\alpha \approx 0.7$ trở đi, tốc độ suy giảm trở nên rõ rệt hơn, đặc biệt đối với DetA.

So với AssA, DetA giảm nhanh hơn khi α tăng, cho thấy hiệu năng của hệ thống bị ảnh hưởng nhiều hơn bởi chất lượng phát hiện đối tượng so với khả năng duy trì danh tính. Nói cách khác, khi tiêu chuẩn đánh giá ngày càng nghiêm ngặt, các sai lệch về vị trí hoặc kích thước hộp giới hạn trở thành nguyên nhân chính làm giảm hiệu năng tổng thể.

Trong khi đó, LocA tăng dần theo α và đạt giá trị cao nhất ở vùng $\alpha > 0.8$. Điều này cho thấy các đối tượng vẫn được xem là khớp ở các ngưỡng cao thường có độ chính xác định vị tốt hơn. Do HOTA được xác định từ cả DetA và AssA, xu hướng giảm của HOTA chủ yếu bị chi phối bởi sự suy giảm của DetA ở các giá trị α lớn.



Hình 8: Kết quả đánh giá theo dõi bằng độ đo HOTA

5 Kết luận

Đồ án đã nghiên cứu bài toán phát hiện, theo dõi và đếm phương tiện từ dữ liệu video giao thông, trong đó trọng tâm là xây dựng một chuỗi xử lý dựa trên học sâu để xác định vị trí phương tiện trong từng khung hình và duy trì định danh của chúng qua thời gian. Phương pháp được đề xuất sử dụng YOLOv8n làm bộ phát hiện phương tiện và kết hợp với thuật toán theo dõi BYTE để liên kết các phát hiện giữa các khung hình. Cách tiếp cận này tận dụng ưu điểm của YOLOv8n về tốc độ và kích thước mô hình nhỏ, đồng thời khai thác khả năng của BYTE trong việc sử dụng cả các phát hiện có độ tin cậy thấp nhằm hạn chế mất dấu đối tượng.

Về mặt thực nghiệm, mô hình YOLOv8n sau khi được fine-tune trên tập dữ liệu UA-DETRAC cho thấy khả năng hội tụ ổn định. Các hàm mất mát trên tập huấn luyện và tập xác thực đều giảm dần, trong khi các chỉ số Precision, Recall và mAP có xu hướng cải thiện trong quá trình huấn luyện. Kết quả đánh giá phát hiện cho thấy mô hình hoạt động tốt đối với các lớp có nhiều mẫu như xe hơi và xe buýt, nhưng còn hạn chế đối với các lớp có ít dữ liệu hơn như xe tải nhỏ và lớp khác. Điều này chứng minh rằng mô hình đã học được các đặc trưng hữu ích của phương tiện trong dữ liệu giao thông, đồng thời cũng cho thấy sự mất cân bằng dữ liệu vẫn là một yếu tố ảnh hưởng đáng kể đến hiệu năng phát hiện.

Đối với bài toán theo dõi, đồ án đã so sánh hai thuật toán SORT và BYTE trên tập xác thực. Kết quả cho thấy BYTE đạt hiệu năng cao hơn SORT trên tất cả các độ đo chính, bao gồm HOTA, MOTA và IDF1. Đặc biệt, BYTE đạt AssA và IDF1 cao hơn, cho thấy khả năng duy trì danh tính đối tượng tốt hơn trong quá trình theo dõi. Trên tập kiểm tra, hệ thống YOLOv8n kết hợp BYTE đạt HOTA bằng 60.716, DetA bằng 59.184, AssA bằng 62.800, MOTA bằng 64.676 và IDF1 bằng 70.345. Các kết quả này chứng minh rằng việc kết hợp bộ phát hiện YOLOv8n với BYTE là một hướng tiếp cận khả thi cho bài toán theo dõi phương tiện trong video giao thông.

Các phân tích theo ngưỡng HOTA cũng cho thấy hiệu năng tổng thể của hệ thống chịu ảnh hưởng lớn từ chất lượng phát hiện. Khi ngưỡng đánh giá trở nên nghiêm ngặt

hơn, DetA giảm nhanh hơn AssA, cho thấy sai lệch về vị trí hoặc kích thước hộp giới hạn là nguyên nhân quan trọng làm giảm chất lượng theo dõi. Như vậy, đề án không chỉ chứng minh được lợi ích của BYTE so với SORT trong việc duy trì định danh, mà còn chỉ ra rằng cải thiện bộ phát hiện là hướng quan trọng để nâng cao hiệu năng của toàn bộ hệ thống.

Ưu điểm chính của phương pháp đề xuất là cấu trúc đơn giản, dễ triển khai và có khả năng cân bằng giữa tốc độ xử lý và độ chính xác. YOLOv8n có kích thước nhỏ, phù hợp với các hệ thống có tài nguyên tính toán hạn chế, trong khi BYTE giúp tận dụng tốt hơn các phát hiện ở nhiều mức độ tin cậy khác nhau. Bên cạnh đó, việc tách riêng bộ phát hiện và bộ theo dõi giúp hệ thống linh hoạt, có thể thay thế hoặc cải tiến từng thành phần mà không cần thay đổi toàn bộ kiến trúc.

Tuy nhiên, phương pháp vẫn còn một số hạn chế. Hiệu năng phát hiện chưa đồng đều giữa các lớp do dữ liệu mất cân bằng, đặc biệt đối với các lớp ít mẫu như *others*. Các đối tượng nhỏ, bị che khuất hoặc xuất hiện ở điều kiện quan sát khó vẫn có thể bị bỏ sót hoặc định vị chưa chính xác, từ đó ảnh hưởng đến kết quả theo dõi. Ngoài ra, hệ thống hiện chủ yếu được đánh giá trên bài toán phát hiện và theo dõi; phần đếm phương tiện vẫn phụ thuộc vào chất lượng quỹ đạo đầu ra và cần được đánh giá sâu hơn trong các kịch bản giao thông thực tế.

Trong tương lai, có thể cải thiện hệ thống theo một số hướng. Thứ nhất, cần xử lý tốt hơn sự mất cân bằng dữ liệu bằng các chiến lược tăng cường dữ liệu, lấy mẫu lại hoặc điều chỉnh hàm mất mát cho các lớp ít mẫu. Thứ hai, có thể thử nghiệm các biến thể YOLO lớn hơn hoặc các kỹ thuật tối ưu suy luận để nâng cao độ chính xác trong khi vẫn đảm bảo tốc độ xử lý. Thứ ba, việc bổ sung các đặc trưng ngoại quan hoặc các thuật toán theo dõi mạnh hơn có thể giúp giảm nhầm lẫn định danh trong các tình huống che khuất. Cuối cùng, cần đánh giá trực tiếp độ chính xác của bài toán đếm phương tiện trên các vùng hoặc đường đếm cụ thể để hoàn thiện hơn hệ thống phục vụ giám sát giao thông tự động.

A Thông tin nhóm

A.1 Thông tin thành viên

Thông tin các thành viên nhóm được trình bày ở Bảng 5.

Bảng 5: Thông tin thành viên nhóm

Tên thành viên	Mã số sinh viên
Hoàng Ngọc Phú [†]	23120010
Hoàng Ngọc Quý	23120077
Nguyễn Duy Bảo	23120113

[†] Nhóm trưởng.

B Mã nguồn bài làm đồ án

Mã nguồn của đồ án được công bố tại GitHub: <https://github.com/kanumi-2005/vehicle-counting>

Tài liệu tham khảo

- Bernardin, K., & Stiefelhagen, R. (2008). Evaluating multiple object tracking performance: The clear mot metrics. *EURASIP Journal on Image and Video Processing*, 2008(1), 246309. Retrieved from <https://doi.org/10.1155/2008/246309> doi: 10.1155/2008/246309
- Dai, Z., Song, H., Wang, X., Fang, Y., Yun, X., Zhang, Z., & Li, H. (2019). Video-based vehicle counting framework. *IEEE Access*, 7, 64460-64470. doi: 10.1109/ACCESS.2019.2914254
- Luiten, J., Ošep, A., Dendorfer, P., Torr, P., Geiger, A., Leal-Taixé, L., & Leibe, B. (2020, October). Hota: A higher order metric for evaluating multi-object tracking. *International Journal of Computer Vision*, 129(2), 548–578. Retrieved from <http://dx.doi.org/10.1007/s11263-020-01375-2> doi: 10.1007/s11263-020-01375-2
- Ristani, E., Solera, F., Zou, R. S., Cucchiara, R., & Tomasi, C. (2016). *Performance measures and a data set for multi-target, multi-camera tracking*. Retrieved from <https://arxiv.org/abs/1609.01775>
- Shokri, D., Larouche, C., & Homayouni, S. (2025). Real-time moving vehicle counting and speed estimation toward efficient traffic surveillance. *IEEE Access*, 13, 36687-36700. doi: 10.1109/ACCESS.2025.3540950
- Song, H., Liang, H., Li, H., Dai, Z., & Yun, X. (2019, December). Vision-based vehicle detection and counting system using deep learning in highway scenes. *European Transport Research Review*, 11(1), 51. doi: 10.1186/s12544-019-0390-4
- Wen, L., Du, D., Cai, Z., Lei, Z., Chang, M.-C., Qi, H., ... Lyu, S. (2020). *Ua-detrac: A new benchmark and protocol for multi-object detection and tracking*. Retrieved from <https://arxiv.org/abs/1511.04136>
- Yang, Z., & Pun-Cheng, L. S. (2018). Vehicle detection in intelligent transportation systems and its applications under varying environments: A review. *Image and Vision Computing*, 69, 143-154. Retrieved from <https://www.sciencedirect.com/science/article/pii/S0262885617301592> doi: <https://doi.org/10.1016/j.imavis.2017.09.008>
- Yaseen, M. (2024). *What is yolov8: An in-depth exploration of the internal features of the next-generation object detector*. Retrieved from <https://arxiv.org/abs/2408.15857>
- Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., ... Wang, X. (2022). *Bytetrack: Multi-object tracking by associating every detection box*. Retrieved from <https://arxiv.org/abs/2110.06864>